

Plateforme d'analyse de la performance publicitaire Meta

Extraction, entrepôt analytique et diagnostic statistique
d'un compte Meta Ads

Rapport de stage — Ingénierie Informatique, spécialité IA & Données

Août 2026

Résumé

Ce rapport présente la conception et la réalisation d'une plateforme d'analyse de la performance publicitaire pour un annonceur du secteur événementiel. Le travail comprend trois couches : un extracteur de l'historique de l'API Meta Marketing conçu pour résister aux limitations de débit et aux interruptions, un entrepôt analytique local de 167144 lignes, et un moteur de diagnostic statistique appliquant une inférence par bootstrap par grappes avec contrôle du taux de fausses découvertes.

L'analyse a mis en évidence trois anomalies chiffrées et actionnables, dont un défaut de suivi des conversions qui empêche l'algorithme d'optimisation de Meta de fonctionner correctement, et un emplacement publicitaire dont le coût par conversion est seize fois supérieur à la moyenne du compte. Une analyse du contenu des publicités établit en outre que les formats qui captent le plus l'attention sont ceux qui convertissent le moins : optimiser sur le taux de clic revient à sélectionner contre la conversion.

Deux hypothèses prédictives ont par ailleurs été testées et écartées, faute de support dans les données. Le rapport insiste sur les précautions méthodologiques qui distinguent un résultat d'un artefact, et sur les limites qui interdisent toute conclusion causale.

Table des matières

1	Contexte et problématique	3
1.1	L'entreprise et son activité publicitaire	3
1.2	Le problème initial	3
1.3	Démarche adoptée	3
2	Architecture de la solution	3
3	Couche 1 — Extraction de l'historique	3
3.1	Pourquoi l'approche naïve échoue	3
3.2	Trois propriétés de robustesse	4
3.3	Les cinq passes d'extraction	4
4	Couche 2 — L'entrepôt et le jeu de données	4
4.1	Un entrepôt sans serveur	4
4.2	Volumétrie et couverture	5
4.3	Une limite majeure : la concentration temporelle	5
4.4	Schéma	5
5	Couche 3 — Méthodologie statistique	6
5.1	Comparer des taux, non des volumes	6
5.2	Le piège de la surdispersion	6
5.3	Bootstrap par grappes	6

5.4	Référence par exclusion	7
5.5	Contrôle des fausses découvertes	7
5.6	Garde-fous	7
6	Résultats	7
6.1	Anomalie critique : le suivi des achats	7
6.2	Emplacements publicitaires	8
6.3	Répartition démographique	9
6.4	Répartition horaire	9
6.5	Simulation de réallocation	10
7	Deux hypothèses mises à l'épreuve	10
7.1	La fatigue créative n'a pas lieu	10
7.2	Détection précoce : un signal réel, un modèle inutile	12
8	Ce que la créative explique, et ce qu'elle n'explique pas	13
8.1	Extraction et variables	13
8.2	L'attention et la conversion s'opposent	13
8.3	Un confondant qui aurait fait la conclusion	14
8.4	Capacité prédictive	14
9	Limites	15
10	Perspectives	15
11	Conclusion	16

1 Contexte et problématique

1.1 L’entreprise et son activité publicitaire

L’entreprise d’accueil commercialise des billets pour des événements culturels au Maroc — concerts, festivals, spectacles d’humour — répartis sur une dizaine de villes. L’acquisition de clients repose presque intégralement sur la publicité payante Meta (Facebook et Instagram).

Chaque événement fait l’objet d’une ou plusieurs campagnes publicitaires. Le volume est important : sur la période étudiée, 106 campagnes, 305 ensembles de publicités et 374 publicités distinctes ont été actifs, pour une dépense totale de 42 781 \$.

1.2 Le problème initial

Le suivi budgétaire était entièrement manuel. Chaque jour, un membre de l’équipe relevait dans l’interface Meta les dépenses de chaque campagne pour les reporter dans un tableur. Ce processus présentait trois faiblesses :

- **Coût en temps** — plusieurs heures hebdomadaires de saisie.
- **Latence** — les écarts entre budget prévu et dépense réelle n’étaient constatés qu’après coup.
- **Absence de profondeur** — seule la dépense agrégée par campagne était suivie. Aucune information sur *qui* voyait les publicités, *où* elles étaient diffusées, ni à *quel moment*.

1.3 Démarche adoptée

Une première phase a consisté à automatiser la collecte quotidienne, supprimant la saisie manuelle. Cette automatisation, opérationnelle, alimente les tableaux de bord de l’équipe.

Ce rapport porte sur la phase suivante : transformer cette collecte opérationnelle en un dispositif d’analyse capable de répondre à la question qui intéresse réellement l’entreprise — *où le budget publicitaire est-il mal employé, et de combien ?*

2 Architecture de la solution

La plateforme s’organise en trois couches indépendantes, chacune consommant la sortie de la précédente.

Couche	Rôle	Sortie
Extraction	Interroger l’API Meta	Fichiers Parquet partitionnés par mois
Entrepôt	Rendre les données requêtables	Base DuckDB, vues SQL
Analyse	Produire un diagnostic	Classement de segments, rapport

TABLE 1 — Les trois couches de la plateforme.

Ce découpage est délibéré. L’extraction est coûteuse et soumise à des quotas : elle ne doit être exécutée qu’une fois. L’analyse, en revanche, est relancée autant de fois que nécessaire sur les données déjà extraites, sans consommer de quota ni dépendre de la disponibilité de l’API.

3 Couche 1 — Extraction de l’historique

3.1 Pourquoi l’approche naïve échoue

L’implémentation évidente consiste à boucler sur les jours et à appeler l’endpoint `GET /insights`. Elle s’effondre rapidement : Meta limite sévèrement le débit des lectures synchrones, et une extraction sur trois ans représente plusieurs milliers d’appels.

La méthode retenue est celle que Meta documente pour l'extraction en masse : les *tâches asynchrones de rapport*.

1. POST /act_<id>/insights → retourne un report_run_id
2. GET /<report_run_id> → interrogation périodique jusqu'au statut Job Completed
3. GET /<report_run_id>/insights → récupération paginée des résultats

Le serveur de Meta assume ainsi l'essentiel du travail d'agrégation, et le nombre d'appels facturés au quota chute d'un ordre de grandeur.

3.2 Trois propriétés de robustesse

Temporisation proactive. Meta indique la consommation du quota dans les en-têtes de chaque réponse (x-business-use-case-usage notamment). Le client les analyse et se met en pause *avant* d'être bloqué, plutôt que de réagir à une erreur 429 déjà survenue. Ce point importe particulièrement ici : le même compte publicitaire sert simultanément les automatisations de production de l'entreprise, qu'une extraction gourmande pourrait paralyser.

Reprise sur interruption. Une extraction de plusieurs heures *sera* interrompue — expiration de jeton, coupure réseau, machine mise en veille. Chaque unité (passe, mois) terminée est enregistrée immédiatement dans un fichier de points de reprise. Relancer le programme repart exactement où il s'était arrêté. Un mois en échec n'est délibérément pas enregistré : il sera retenté au lancement suivant, de sorte que l'extraction converge sur plusieurs exécutions au lieu d'exiger une réussite ininterrompue.

Découpage mensuel. Le travail est fractionné par mois calendaire. Les tâches asynchrones restent assez petites pour que Meta les termine, les points de reprise gagnent une granularité utile, et des résultats partiels sont exploitables au bout de quelques minutes.

3.3 Les cinq passes d'extraction

Passe	Segmentation	Lignes	Part
base	aucune	3 643	2,2 %
age_gender	âge × genre	43 422	26,0 %
placement	plateforme × position × appareil	88 497	52,9 %
region	région	6 719	4,0 %
hourly	heure de la journée	24 863	14,9 %
Total		167 144	

TABLE 2 – Volumétrie par passe d'extraction.

La profondeur du jeu de données ne vient pas de la longueur de l'historique mais de la *segmentation* : une même dépense observée sous cinq angles différents.

4 Couche 2 — L'entrepôt et le jeu de données

4.1 Un entrepôt sans serveur

Les fichiers Parquet produits par l'extraction sont exposés comme une base DuckDB. Aucune donnée n'est recopiée : DuckDB lit les partitions sur place, si bien qu'une reconstruction après une nouvelle extraction est instantanée et que les fichiers restent la source de vérité. Le partitionnement de type Hive rend les clés **pass** et **month** lisibles comme des colonnes, avec élagage automatique des partitions.

Ce choix évite d’installer et d’administrer un serveur de base de données pour un volume qui tient dans 21 Mo, tout en conservant une interface SQL complète.

4.2 Volumétrie et couverture

Publicités distinctes	374
Ensembles de publicités	305
Campagnes	106
Jours avec activité	65
Dépense totale	42 781 \$
Impressions	73 312 065

TABLE 3 – Caractéristiques du jeu de données extrait.

4.3 Une limite majeure : la concentration temporelle

L’API Meta conserve environ 37 mois d’historique, et l’extraction a bien parcouru cette fenêtre complète. Le résultat est cependant très déséquilibré :

Mois	Lignes	Dépense (\$)
2023-10	89	253
2026-02	31	20
2026-03	13	0
2026-06	43	106
2026-07	2 249	29 320
2026-08	1 218	13 082

TABLE 4 – Répartition mensuelle. Les mois absents ne contiennent aucune donnée.

Plus de 95 % des données portent sur juillet et août 2026. Le compte publicitaire est resté quasi inactif entre octobre 2023 et juin 2026. On ne dispose donc pas de trois ans d’historique mais d’environ deux mois d’activité réelle.

Cette contrainte a été identifiée avant le cadrage analytique, et elle l’a orienté. Elle écarte définitivement toute modélisation exigeant de la saisonnalité — modèle de mix marketing, prévision à long terme, comparaison d’une année sur l’autre — et concentre le travail sur ce que deux mois de données denses et finement segmentées permettent réellement d’établir.

4.4 Schéma

Chaque ligne représente une entité (publicité ou campagne) pour un jour donné, et pour un segment lorsque la passe en définit un.

- **Identité** — date, identifiants et noms de campagne, ensemble et publicité
- **Diffusion** — impressions, clics, dépense, couverture, répétition, CPM, CPC, CTR
- **Entonnoir** — clic sur lien, vue de page, vue de contenu, recherche, ajout au panier, initiation de paiement, achat, et la valeur monétaire associée à chacun
- **Engagement** — vues de vidéo, interactions, commentaires

Les compteurs de conversion utilisent un type entier acceptant la valeur nulle, afin de distinguer « Meta n’a rien remonté » de « Meta a remonté zéro ». La distinction est essentielle pour modéliser un entonnoir. Le contenu brut renvoyé par l’API est également conservé, de sorte qu’un type d’action non anticipé reste récupérable.

5 Couche 3 — Méthodologie statistique

Cette section détaille les choix méthodologiques, car ils déterminent la fiabilité des résultats de la section suivante.

5.1 Comparer des taux, non des volumes

Un segment ayant reçu dix fois le budget d'un autre doit convertir dix fois plus avant d'être jugé performant. La dépense joue donc le rôle d'exposition, et le modèle naturel est un taux de Poisson :

$$C_i \sim \mathcal{P}(\lambda_i \cdot s_i) \quad (1)$$

où C_i est le nombre de conversions du segment i , s_i sa dépense, et λ_i son taux de conversion par unité monétaire. L'indice de performance rapporté dans les résultats est le rapport entre conversions observées et attendues sous le taux global $\bar{\lambda}$:

$$I_i = \frac{C_i}{\bar{\lambda} \cdot s_i}, \quad \bar{\lambda} = \frac{\sum_j C_j}{\sum_j s_j} \quad (2)$$

Une valeur $I_i = 1$ signifie que le segment se comporte exactement comme la moyenne du compte.

5.2 Le piège de la surdispersion

La première implémentation testait λ_i contre $\bar{\lambda}$ au moyen d'un test du score, en corrigeant la surdispersion par un paramètre de Pearson :

$$\hat{\phi} = \frac{1}{n-1} \sum_i \frac{(C_i - \bar{\lambda} s_i)^2}{\bar{\lambda} s_i} \quad (3)$$

Cette approche a produit un résultat incohérent : $\hat{\phi} = 52$, et plus aucun segment significatif — alors même que les intervalles de confiance de certains segments ne se recouvraient pas.

L'explication est que $\hat{\phi}$ est estimé sur les écarts *entre* segments, c'est-à-dire précisément sur l'effet que le test cherche à détecter. Le dispositif s'auto-annulait : plus les segments diffèrent réellement, plus la correction gonfle et masque cette différence.

Le paramètre de dispersion reste calculé et affiché à titre de diagnostic, mais il ne pilote plus la décision statistique.

5.3 Bootstrap par grappes

L'inférence repose désormais sur un bootstrap non paramétrique. Le choix de l'unité de rééchantillonnage est déterminant.

Les lignes sont des observations (publicité, jour) ; or les jours d'une même publicité partagent le même visuel, la même audience et la même enchère. Ils ne constituent pas des observations indépendantes. Rééchantillonner les lignes traiterait ces répétitions comme autant de preuves distinctes et produirait des intervalles beaucoup trop étroits.

Le bootstrap rééchantillonne donc les *publicités* entières, avec remise. Pour B répliques et un segment comptant K publicités :

$$\lambda^{(b)} = \frac{\sum_{k \in \mathcal{S}_b} C_k}{\sum_{k \in \mathcal{S}_b} s_k}, \quad \mathcal{S}_b \sim \text{Uniforme}(\{1, \dots, K\})^K \quad (4)$$

Le passage au bootstrap par grappes a élargi les intervalles d'environ 20 %, ce qui correspond à l'effet attendu lorsque l'on cesse de sur-compter des observations corrélées.

5.4 Référence par exclusion

Chaque segment est comparé non pas à la moyenne globale — qui l’inclut — mais au taux agrégé de tous les *autres* segments :

$$\lambda_{-i} = \frac{\sum_{j \neq i} C_j}{\sum_{j \neq i} s_j} \quad (5)$$

Sans cette précaution, un segment assez gros pour dominer la moyenne se retrouverait comparé à lui-même, ce qui atténuerait mécaniquement tout écart.

5.5 Contrôle des fausses découvertes

Tester 150 segments au seuil $\alpha = 0,05$ produit mécaniquement une poignée de faux positifs. Les valeurs p issues du bootstrap sont donc ajustées par la procédure de Benjamini–Hochberg, qui contrôle le taux de fausses découvertes :

$$q_{(k)} = \min_{j \geq k} \left\{ \min \left(1, \frac{m}{j} p_{(j)} \right) \right\} \quad (6)$$

Le contrôle du FDR plutôt que du risque familial est ici le bon compromis : l’objectif est une liste restreinte de pistes à instruire, non une garantie absolue sur chaque élément.

5.6 Garde-fous

- Un segment doit dépasser *à la fois* un nombre minimal de conversions attendues et une part minimale de la dépense totale. Le premier seuil protège l’approximation normale ; le second, indépendant de l’échelle, écarte les segments dérisoires. Sans lui, un segment représentant 1 \$ de dépense ressortait comme significatif sur la dimension géographique, où le taux de clics par dollar est élevé.
- Les segments exclus sont comptés et signalés, jamais silencieusement écartés : un filtre invisible est un biais invisible.
- Les dimensions pour lesquelles Meta ne remonte aucune conversion sont traitées en classement seul, sans recommandation budgétaire.

6 Résultats

6.1 Anomalie critique : le suivi des achats

L’entonnoir se comporte normalement jusqu’à l’initiation de paiement, puis s’effondre :

Étape	Volume	Taux de passage
Vues de page de destination	694 134	—
Ajouts au panier	43 564	6,3 %
Initiations de paiement	9 004	20,7 %
Achats	26	0,29 %

TABLE 5 – Progression dans l’entonnoir sur l’ensemble de la période.

Un taux de passage du paiement à l’achat se situe habituellement entre 40 et 70 % dans le commerce en ligne. La valeur observée est inférieure de deux ordres de grandeur. Il ne s’agit pas d’un problème commercial mais d’un **défaut technique du pixel de suivi** : l’événement **Purchase** ne se déclenche pas correctement sur la page de confirmation de paiement.

Les conséquences sont lourdes :




FIGURE 1 – Entonnoir de conversion complet, échelle logarithmique. La chute finale est de trois ordres de grandeur.

- **L’algorithme de Meta optimise à l’aveugle.** Il ne peut pas apprendre à cibler des acheteurs s’il n’en observe que quelques dizaines. Les campagnes s’optimisent en pratique sur l’ajout au panier ou le trafic, ce qui est nettement moins efficace.
- **Le retour sur investissement affiché est faux**, et toute décision budgétaire fondée sur lui est biaisée.
- **Le reciblage des paniers abandonnés** est dégradé.

Corriger ce pixel est vraisemblablement l’action à plus fort impact sur l’ensemble du compte. C’est aussi la moins coûteuse.

En conséquence, toutes les analyses de ce rapport prennent l’initiation de paiement comme mesure de conversion. C’est l’étape la plus profonde de l’entonnoir dont le suivi soit fiable, et c’est la pratique usuelle lorsque le suivi des achats est défaillant.

6.2 Emplacements publicitaires




FIGURE 2 – Coût par initiation de paiement selon l’emplacement. En vert, les emplacements plus efficaces que la moyenne du compte.

L'écart entre le meilleur et le pire emplacement est d'un facteur 16.

Emplacement	Dépense (\$)	Conv.	Coût (\$)	Signif.
instagram / feed	8 157	2 298	3,55	oui
facebook / feed	6 879	1 817	3,79	oui
instagram / stories	5 628	1 432	3,93	oui
instagram / reels	10 589	2 181	4,85	non
facebook / stories	724	129	5,61	non
facebook / instream video	614	85	7,22	oui
facebook / reels	6 434	881	7,30	oui
audience network / rewarded	448	13	34,46	oui
audience network / classic	3 107	53	58,62	oui

TABLE 6 – Performance par emplacement. « Signif. » indique un écart survivant au contrôle du taux de fausses découvertes.

Deux cibles se dégagent :

Audience Network. 3 555 \$ dépensés pour un coût par conversion de 58,62 \$, contre 3,55 \$ sur le fil Instagram. Le réseau d'audience diffuse sur des applications tierces, où la qualité du trafic est notoirement faible. Sa désactivation ne demande qu'un réglage et ne comporte pas de contrepartie identifiable.

Facebook Reels. 6 434 \$, soit 15 % du budget, pour un coût double de celui du fil Instagram. Le cas est moins tranché : ce format sert peut-être un objectif de notoriété que la mesure du paiement ne capte pas. L'écart mérite néanmoins d'être discuté avec l'équipe média.

6.3 Répartition démographique




FIGURE 3 – Coût par conversion par tranche d'âge et par genre.

Les segments féminins de 25–34 et 35–44 ans ressortent significativement au-dessus de la moyenne (indice 1,40 ; $q = 0,001$), avec un coût par conversion de 3,40 \$. Le segment masculin 25–34 ans, qui reçoit pourtant la dépense la plus élevée du compte (9 261 \$), affiche 5,20 \$.

Globalement, les segments masculins captent 55 % du budget pour 45 % des conversions.

6.4 Répartition horaire

Les heures nocturnes, de 3 h à 8 h, présentent un coût significativement supérieur : jusqu'à 10,64 \$ à 5 h contre 4,25 \$ à 14 h. Environ 2 400 \$ sont dépensés dans cette plage. Une restriction




FIGURE 4 – Coût par conversion selon l’heure de diffusion.

horaire est envisageable, sous réserve de vérifier que ces heures ne servent pas à capter une audience spécifique.

6.5 Simulation de réallocation

En déplaçant la dépense des segments significativement sous-performants vers les segments significativement performants, en proportion de leur dépense actuelle :

Dimension	Plafond linéaire	Estimation saturée
Emplacement	+20,4 %	+12,9 %
Démographie	+17,7 %	+10,0 %

TABLE 7 – Gain de conversions estimé à budget constant.

Deux bornes sont rapportées plutôt qu’une valeur unique. Le plafond linéaire suppose que le budget déplacé convertit au taux actuel du segment receveur : c’est un majorant certainement optimiste, aucun canal ne conservant son efficacité lorsque son budget augmente. L’estimation saturée suppose des rendements décroissants :

$$C_{\text{nouveau}} = C_{\text{actuel}} \left(\frac{s_{\text{nouveau}}}{s_{\text{actuel}}} \right)^{\alpha}, \quad \alpha = 0,8 \quad (7)$$

La valeur $\alpha = 0,8$ est une hypothèse issue de la littérature sur les courbes de réponse publicitaire, non une mesure effectuée sur ces données.

7 Deux hypothèses mises à l’épreuve

Les résultats précédents sont descriptifs. Cette section rapporte deux tentatives de modélisation prédictive. Aucune n’a abouti au livrable envisagé, et les raisons de cet échec sont plus instructives que ne l’aurait été un modèle bien ajusté.

7.1 La fatigue créative n’a pas lieu

L’hypothèse. Un visuel publicitaire s’épuise : à mesure que la même audience le revoit, l’attention décroît, le taux de clic chute et le coût par conversion se dégrade. C’est un phénomène documenté, et la structure des données s’y prêtait : 374 publicités, des durées de diffusion allant de 1 à 34 jours, et une censure à droite propre — les publicités encore actives à la date d’extraction

(figure 5). Un estimateur de Kaplan–Meier suivi d’un modèle à risques proportionnels semblait indiqué.




FIGURE 5 — Distribution des durées de diffusion et fonction de survie empirique des 374 publicités. La structure convenait à une analyse de survie.

Trois tests convergents. Avant d’ajuster quoi que ce soit, il fallait vérifier que le phénomène existe.




FIGURE 6 — À gauche, CTR médian par jour de diffusion sur les 43 publicités diffusées au moins 12 jours. À droite, distribution des pentes du CTR estimées publicité par publicité. La ligne pleine marque la pente moyenne et la ligne pointillée l’absence d’effet : elles se confondent, ce qui est précisément le résultat.

1. **Profil agrégé.** Sur les 43 publicités diffusées au moins 12 jours, le CTR médian creuse légèrement vers le septième jour puis *remonte*. Aucune décroissance monotone.
2. **Régression intra-publicité.** La pente relative du CTR, estimée séparément pour chaque publicité, vaut en moyenne $-0,11$ % par jour et en médiane $+0,52$ %. Seules 44 % des publicités déclinent — soit un tirage à pile ou face. Le test de Student contre zéro donne $t = -0,23$, $p = 0,82$.
3. **Le mécanisme manque.** La fréquence quotidienne passe de 1,29 sur les trois premiers jours à 1,23 entre le huitième et le douzième, puis 1,19 au-delà du quinzième. Elle *diminue* au lieu de s’accumuler.

Explication. Le troisième point détermine les deux autres. La fatigue créative suppose qu’une même personne voie l’annonce de plus en plus souvent. Or à environ 25 \$ par jour et par publicité,

face à une audience marocaine de plusieurs millions de personnes, le vivier ne sature jamais : chaque journée touche une audience largement neuve. Sans exposition cumulée, il n'existe aucun mécanisme par lequel la fatigue pourrait s'installer.

Pourquoi aucun modèle n'a été ajusté. Deux voies restaient ouvertes, toutes deux fautives. Modéliser le « temps jusqu'à la fatigue » aurait produit une courbe de survie décrivant du bruit. Modéliser le « temps jusqu'à l'arrêt » aurait été techniquement valide — l'événement est réel et observé — mais les publicités s'arrêtent parce que le concert a eu lieu ou que l'équipe a coupé le budget. Le modèle aurait décrit le calendrier des événements en l'habillant en analyse de survie : sophistiqué en apparence, vide en substance.

Valeur du résultat négatif. Il est directement actionnable : **le renouvellement préventif des visuels sur un calendrier fixe n'est pas justifié sur ce compte**. Cette pratique, standard en achat média et coûteuse en production, répondrait ici à un problème inexistant.

7.2 Détection précoce : un signal réel, un modèle inutile

La question. Celle que le media buyer se pose au deuxième jour : *cette publicité mérite-t-elle qu'on continue à la financer ?*

Protocole. Les variables explicatives sont mesurées sur les jours 1 et 2 ; la cible — l'efficacité, en initiations de paiement par dollar — est calculée à partir du jour 3. Les fenêtres sont disjointes, aucune observation ne figure des deux côtés. L'apprentissage porte sur les publicités lancées en juillet, le test sur celles lancées en août. Le seuil séparant « bonnes » et « mauvaises » publicités est la médiane de l'échantillon d'apprentissage, appliquée telle quelle au test.




FIGURE 7 — Aire sous la courbe ROC selon le protocole d'évaluation, avec intervalle de confiance bootstrap à 95 %.

Résultats. Trois enseignements, visibles figure 7.

Le signal existe. En validation croisée dont les plis sont groupés par campagne — aucune campagne ne figure simultanément en apprentissage et en test — l'aire sous la courbe atteint 0,73, intervalle [0,65 ; 0,80]. Le hasard est nettement exclu : les deux premiers jours portent bien de l'information sur la suite.

Le modèle est battu par une seule variable. Le classement par la seule efficacité précoce atteint 0,78, contre 0,73 pour la régression logistique à six variables. Avec 174 observations et des variables corrélées, le modèle ajoute du bruit plutôt que du signal. L'écart entre apprentissage (0,86) et test confirme un sur-apprentissage résiduel malgré la régularisation.

La généralisation temporelle n'est pas démontrée. Sur la séparation juillet → août, l'aire tombe à 0,60 avec un intervalle [0,39 ; 0,79] contenant 0,50. Deux lectures restent possibles — soit le signal ne se transporte pas d'un mois à l'autre, soit les 37 publicités de test ne suffisent pas à le détecter — et rien dans ces données ne permet de les départager.

Une limite structurelle. La corrélation entre efficacité précoce et efficacité tardive vaut $\rho = 0,46$ toutes campagnes confondues, mais seulement $\rho = 0,20$ une fois l'effet campagne retiré. L'essentiel du pouvoir prédictif distingue les campagnes, non les créatives d'une même campagne. L'outil convient à l'arbitrage de portefeuille, pas au choix d'un visuel parmi ses frères — distinction qu'une aire sous la courbe flatteuse aurait entièrement masquée.

Le livrable retenu. Non pas un modèle, mais une règle : **classer les publicités par initiations de paiement par dollar au deuxième jour et signaler le dernier quartile**. Elle est interprétable, calculable dans un tableur, ne demande ni réentraînement ni surveillance, et elle est mesurablement plus performante que le modèle qu'elle remplace.

Un dernier point mérite d'être noté : le taux de clic ne prédit rien ($\rho = -0,10$, aire sous la courbe 0,41). Juger une publicité sur son CTR — réflexe courant en achat média — est trompeur sur ce compte. Seul le signal de conversion précoce porte de l'information.

8 Ce que la créative explique, et ce qu'elle n'explique pas

Les sections précédentes mesurent des résultats sans jamais regarder ce qui les a produits. Cette dernière analyse joint à chaque publicité son *contenu* — le texte lu par le spectateur et l'image qu'il a vue — pour déterminer quels choix créatifs portent un signal.

8.1 Extraction et variables

Les créatives sont récupérées sur une autre arête de l'API, une pagination classique sans tâche asynchrone. Sur les 360 publicités ayant diffusé, le texte publicitaire est disponible à 100 %, le type d'objet et l'appel à l'action également, et une vignette a pu être téléchargée pour chacune.

Vingt-et-une variables sont construites :

- **Texte** (12) — longueur, nombre de mots, de lignes, d'emojis, de mentions, d'exclamations, de questions ; proportion de majuscules ; présence d'un marqueur d'urgence, d'un prix, d'une date.
- **Image** (7) — ratio d'aspect, luminosité, saturation, contraste, *colorfulness* au sens de Hasler et Süssstrunk, densité de contours, part de pixels sombres.
- **Format** (2) — vidéo ou image fixe, Reel ou non.

Aucun modèle de vision pré-entraîné n'est employé. Avec 360 images réparties sur 89 campagnes, une représentation profonde fournirait des centaines de dimensions que les données ne peuvent pas soutenir. Ces variables sont peu nombreuses, interprétables, et chacune correspond à une décision qu'un graphiste peut appliquer.

8.2 L'attention et la conversion s'opposent

Deux cibles sont modélisées séparément : le taux de clic, qui mesure l'attention captée, et les initiations de paiement par dollar, qui mesurent la conversion obtenue. Le résultat est systématique.

Les formats qui captent le plus l'attention — vidéo, format vertical, Reel — sont ceux qui convertissent le moins. Les visuels statiques à fort contraste font exactement l'inverse. L'ampleur est comparable dans les deux sens, autour de $|\rho| \approx 0,2$ pour la conversion et 0,4 pour l'attention.




FIGURE 8 – Corrélation de chaque trait créatif avec l’attention (à gauche) et avec la conversion (à droite), après retrait de l’effet campagne. Les traits qui gagnent des clics en perdent en conversion, et réciproquement.

Ces corrélations sont calculées **après centrage par campagne**. Elles ne reflètent donc pas le fait que certains événements se vendent mieux que d’autres : elles comparent des créatives entre elles, à l’intérieur d’une même campagne, pour un même événement et une même audience.

Conséquence directe. Sélectionner les créatives sur le taux de clic — réflexe naturel, et la métrique que l’interface de Meta met en avant — revient à sélectionner *contre* la conversion. Ce constat complète celui de la section 7, où l’efficacité précoce prédisait la suite mais où le taux de clic n’y parvenait pas ($\rho = -0,10$). On en connaît maintenant le mécanisme : le format pousse les deux métriques en sens opposés.

8.3 Un confondant qui aurait fait la conclusion

La corrélation brute la plus forte de toute l’analyse était la proportion de majuscules dans le texte : $\rho = -0,346$ avec le taux de clic, $q = 2 \cdot 10^{-7}$, de loin la plus significative.

Une fois l’effet campagne retiré, elle tombe à $-0,129$ et cesse d’être significative. Sur la conversion, elle passe de $+0,239$ à $-0,083$: le signe s’inverse.

Il s’agissait d’un pur effet de campagne — certains événements emploient un style typographique particulier *et* se vendent bien, sans lien de cause à effet entre les deux. Sans ce contrôle, cette variable aurait constitué le résultat phare de la section.

8.4 Capacité prédictive

Cible	Modèle	AUC	IC 95 %
Attention (CTR)	régression logistique	0,697	[0,630 ; 0,759]
	gradient boosting	0,662	[0,593 ; 0,728]
Conversion	régression logistique	0,603	[0,534 ; 0,669]
	gradient boosting	0,616	[0,547 ; 0,677]

TABLE 8 – Validation croisée à plis groupés par campagne, 260 publicités retenues (dépense d’au moins 20 \$).

La créative explique correctement l'attention et mal la conversion. Le résultat est cohérent : ce qui décide de l'achat d'un billet — l'artiste, la ville, la date, le prix — ne se trouve pas dans le visuel. Celui-ci arbitre qui s'arrête sur l'annonce, pas qui achète.

On notera que le gradient boosting ne surpasse pas la régression logistique, pour la troisième fois de ce travail. Lorsqu'un modèle non linéaire n'apporte rien, le plafond tient aux données et non à la classe de modèle.

9 Limites

Les résultats ci-dessus doivent être lus avec les réserves suivantes.

Nature observationnelle. Ces données décrivent des allocations que l'algorithme de Meta a lui-même choisies, en fonction de signaux que le jeu de données ne contient pas. Qu'un segment convertisse mieux n'implique pas qu'y transférer du budget produira le même rendement. Seule une expérimentation contrôlée — test géographique ou partition d'audience — peut trancher. Les simulations dimensionnent l'enjeu et justifient de mener ce test ; elles ne le remplacent pas.

Profondeur temporelle. Deux mois d'activité réelle, sur une seule saison. Aucun effet saisonnier ne peut être estimé, et rien ne garantit que ces écarts persistent hors de la période estivale.

Mesure de conversion dégradée. L'analyse porte sur l'initiation de paiement et non sur l'achat, faute d'un suivi fiable de ce dernier. Si le taux de transformation du paiement à l'achat varie selon les segments, le classement s'en trouve biaisé.

Recommandations non littérales. Certaines conclusions ne sont pas directement applicables. Le modèle indique par exemple de transférer 22 000 \$ d'Android vers iPhone, ce qui n'a pas de sens opérationnel : l'inventaire publicitaire iPhone est fini et ne saurait absorber un doublement de la dépense. L'écart de performance entre systèmes constitue un signal directionnel — il suggère d'examiner l'expérience de paiement sur Android — et non une instruction budgétaire.

10 Perspectives

Quatre prolongements se dégagent, dont deux imposés par les résultats de la section 7.

Valider expérimentalement. C'est le prolongement le plus urgent et le moins coûteux. Toutes les recommandations de ce rapport reposent sur des données observationnelles. Un test contrôlé sur Audience Network — désactivation sur une moitié des campagnes, maintien sur l'autre, pendant deux semaines — trancherait définitivement le cas le plus net, pour un risque budgétaire faible au vu du coût par conversion actuel de cet emplacement.

Constituer un second jeu de test temporel. La question laissée ouverte par la détection précoce — le signal se transporte-t-il d'un mois à l'autre ? — se règlera mécaniquement lorsque septembre fournira un nouvel échantillon. Le protocole est déjà écrit et n'aura qu'à être relancé.

Approfondir l'analyse créative. La section 8 s'en tient à des statistiques perceptuelles simples, faute d'un volume permettant une représentation profonde. Avec quelques centaines de publicités supplémentaires, un modèle de vision fournirait des descripteurs plus riches — présence et cadrage du visage de l'artiste, texte incrusté, type de scène — dont l'analyse actuelle établit qu'ils mériteraient d'être mesurés.

Correction du suivi et remesure. Une fois le pixel **Purchase** réparé, l'ensemble des analyses devrait être reconduit sur la mesure d'achat réelle, qui est la seule alignée sur l'objectif commercial.

11 Conclusion

Ce travail a transformé une automatisation de saisie en un dispositif d'analyse capable de produire un diagnostic chiffré sur l'emploi du budget publicitaire.

Sur le plan technique, la contribution principale réside moins dans la quantité de code que dans les choix de robustesse : extraction asynchrone conforme aux contraintes de l'API, temporisation proactive préservant les systèmes de production, reprise sur interruption, et surtout une méthodologie statistique qui refuse de produire des résultats commodes. La correction du dispositif d'inférence — abandon d'une correction de surdispersion qui absorbait le signal, au profit d'un bootstrap par grappes respectant la structure de dépendance des données — illustre cette exigence.

Sur le plan métier, trois constats actionnables ont été établis, dont un défaut de suivi qui compromet l'optimisation de l'ensemble du compte. La simulation de réallocation situe le gain potentiel entre 10 et 20 % de conversions supplémentaires à budget constant, sous réserve de validation expérimentale.

La principale limite est la profondeur temporelle des données. Elle a été identifiée en amont du cadrage analytique, et a conduit à écarter les approches qu'elle rendait indéfendables plutôt qu'à les mener malgré tout.